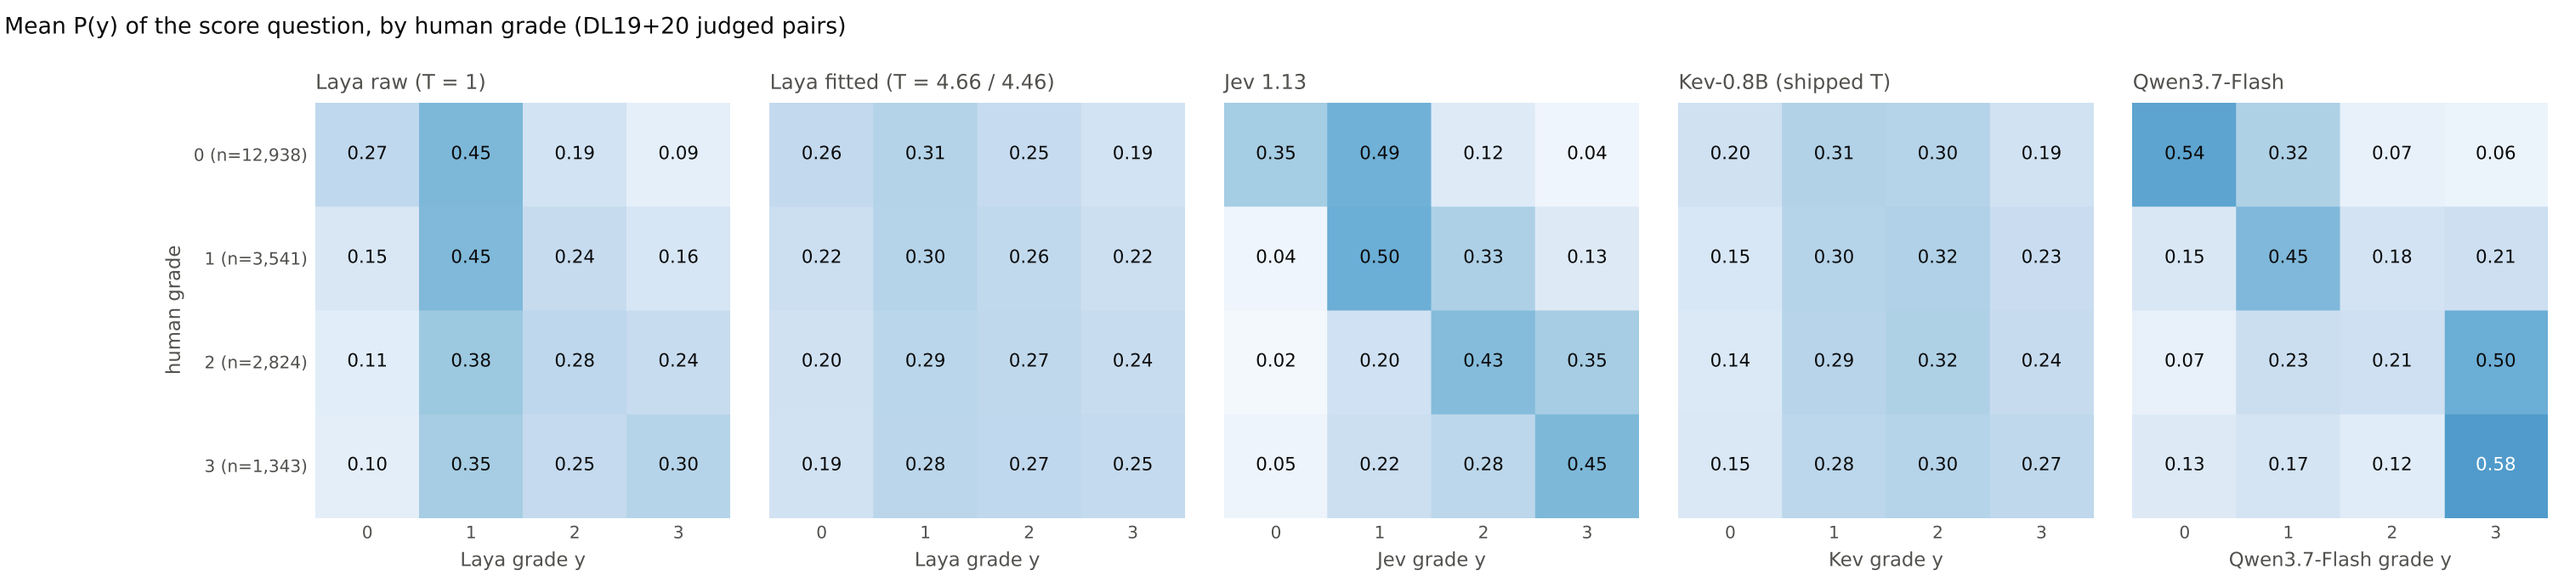
Mean P(y) of the score question, by human grade (DL19+20 judged pairs)
Laya raw (T = 1)
Laya fitted (T = 4.66 / 4.46)
Jev 1.13
Kev-0.8B (shipped T)
Qwen3.7-Flash
human grade
0 (n=12,938)
1 (n=3,541)
2 (n=2,824)
3 (n=1,343)
0.27 0.45 0.19 0.09
0.15 0.45 0.24 0.16
0.11 0.38 0.28 0.24
0.10 0.35 0.25 0.30
0.26 0.31 0.25 0.19
0.22 0.30 0.26 0.22
0.20 0.29 0.27 0.24
0.19 0.28 0.27 0.25
0.35 0.49 0.12 0.04
0.04 0.50 0.33 0.13
0.02 0.20 0.43 0.35
0.05 0.22 0.28 0.45
0.20 0.31 0.30 0.19
0.15 0.30 0.32 0.23
0.14 0.29 0.32 0.24
0.15 0.28 0.30 0.27
0.54 0.32 0.07 0.06
0.15 0.45 0.18 0.21
0.07 0.23 0.21 0.50
0.13 0.17 0.12 0.58
0 1 2 3
Laya grade y
Laya grade y
Jev grade y
Kev grade y
Qwen3.7-Flash grade y